



中國石油大學 (华东)
CHINA UNIVERSITY OF PETROLEUM

机器学习实践报告

课 程: 机器学习实践

系 别: 人工智能系

专 业: 本研一体化 (人工智能类)

年 级: 2024 级

小 组: 19

姓 名: 高维杰、申英辰、周艺涵、张益恺、段皓阳

指导教师: 刘昕

2026 学年 第 3 学期

基于多源融合与多架构对比的脑肿瘤 MRI 四分类辅助诊断研究

一、项目背景与研究意义（高维杰）

1.1 项目背景

脑肿瘤的早期发现与准确分型对治疗方案制定和患者生存率提升至关重要。磁共振成像（MRI）因其无创与软组织对比度高等优势，已成为脑肿瘤临床诊断的核心影像学手段。然而，MRI 影像判读高度依赖放射科医师的专业经验，在阅片量激增和基层医疗资源不足的背景下，人工阅片效率有限且易因疲劳导致误诊与漏诊。因此，构建基于机器学习的辅助诊断系统，对于提升筛查效率、降低误诊率具有重要的临床价值与社会意义。

近年来，深度学习在医学图像分类领域取得显著进展，但脑肿瘤 MRI 辅助诊断仍面临若干关键挑战：公开数据集规模有限且来源单一，模型易产生过拟合与领域偏移；不同数据集的标签体系、成像设备与扫描协议存在显著异质性，直接混合使用会引入严重偏差；深度学习模型的“黑箱”特性使其在临床落地时面临可解释性不足的质疑。

针对上述问题，本项目聚焦于脑肿瘤 MRI 四分类任务（glioma、meningioma、pituitary、notumor），整合四个公开的异质性医学影像数据集，构建了一个规模更大的融合语料库。在数据层面，设计了一套系统的标准化与清洗流水线；在模型层面，从多个技术路线展开系统性对比实验，涵盖基于手工特征与液态动力学的 GKLNN、基于 ImageNet-21k 预训练的 ViT-Base/16、ResNet50V2、融合注意力机制的 DeepSCNN 双视图网络，以及现代 CNN 架构 ConvNeXt Tiny，全面评估不同方法在脑肿瘤 MRI 分类任务上的性能、泛化能力与推理效率。

1.2 研究意义

一是数据层面，验证了多源异构数据集标准化融合的有效性，为后续多中心联合建模提供方法参考；二是模型层面，首次在同一测试基准上系统对比多样化架构，并通过可解释性分析暴露了模型的捷径学习问题；三是临床层面，所构建的高精度辅助诊断系统有望为放射科医生提供决策支持，推动 AI 辅助诊疗从理论研究向实际临床应用的转化。

二、数据集介绍（高维杰）

本项目聚焦于脑肿瘤 MRI（磁共振成像）辅助诊断这一课题，通过整合多个公开的、异质性的医学影像数据集，构建了一个规模更大的训练语料库，以提升分类模型的泛化能力，克服单一数据源带来的过拟合与领域偏移问题。

2.1 数据来源与原始构成

本研究所用数据源自四个公开的脑部 MRI 影像数据集：**Brain Tumor MRI Dataset**、**BRISC 2025 Dataset (classification task)**、**BrainTumorDataPublic** 和 **NINS_Dataset**。四个源数据集初始输入样本为 **18241** 张图像/切片。然而，这些数据在标签和内容层面均存在显著异质性，直接混合使用将引发严重问题，因此必须进行系统的标准化与清洗。

2.2 数据标准化与融合

（1）两级级联去重策略

为防止不同数据集之间因数据引用、复制或高度相似的成像切片而导致的数据泄露和评估结果虚高，流水线实施了严格的**两级去重机制**，处理顺序严格按照 **Brain Tumor MRI Dataset** → **BRISC 2025 Dataset (classification task)** → **BrainTumorDataPublic** → **NINS_Dataset** 的优先级进行。

第一级为 **SHA-256 精确哈希去重**，即计算源文件完整的二进制字节流的 SHA-256 散列值，并与所有已保留图像的哈希值比对。若发生碰撞，则判定源文件为重复文件并移除。

第二级为 **pHash 感知哈希近似去重**，对于 SHA-256 未命中但视觉内容高度相似的图像，采用感知哈希算法进行近似匹配：将输入图像转换为 RGB 色彩空间 → 应用离散余弦变换（DCT）提取图像的低频特征 → 生成 64 位的感知哈希指纹 → 计算当前图像与所有已保留图像 pHash 之间的**汉明距离（Hamming Distance）**。若最小汉明距离 ≤ 3 ，则判定为近似重复并移除。

2.3 混合数据集统计与输出

经过完整的标准化与去重流程后，最终保留了 **11540** 张高质量图像：

来源	原始输入	保留数量
Brain Tumor MRI Dataset	7200	5713
BRISC 2025 Dataset	6000	1180
BrainTumorDataPublic	3064	2931
NINS	1977	1716

最终按类别统计的输出分布如下表所示：

类别	保留数量	占比
glioma	3171	27.5%
meningioma	2380	20.6%
notumor	3374	29.2%
pituitary	2615	22.7%
合计	11540	100%

值得注意的是，合并后的数据集**不再保留原始的 train/test 划分信息**，所有样本统一标记。这一设计是为了在后续预处理阶段进行**分层抽样**重新划分，确保训练、验证和测试三个集合在各个类别上的分布比例完全一致。

三、数据探索性统计分析（高维杰）

我们对最终保留的 11540 张图像进行了系统性的探索性分析，目的在于深入理解数据的内在分布规律、识别潜在的噪声与异常模式、并为后续预处理策略的制定提供数据驱动的决策依据。

3.1 类别分布均衡性分析

类别分布的均衡性直接影响分类器的训练动态与评估指标的解释力。我们首先对样本标签进行频数统计，并绘制如下柱状图与饼图，以反映各类别的分布特征。




图 1 类别分布统计图

从柱状图可以直观看出，四个类别的样本量均落在 2300 至 3400 的区间内，其中样本量最大的 notumor 类为 3374 张，最小的 meningioma 类为 2380 张，两者之比约为 1.42:1，远低于严重不平衡阈值。基于此观察，可以判定该数据集具有**良好的类别均衡性**，在后续模型训练中**无需**采用过采样、欠采样或代价敏感学习等专门的不平衡处理策略，优先使用标准交叉熵损失函数即可获得无偏的优化结果。

3.2 图像分辨率与存储特征分析

了解图像的空间尺寸分布对于确定统一的输入尺寸至关重要。我们通过遍历所有图像的 width 和 height 属性，计算均值、标准差、最小值、最大值等统计量，并绘制宽度直方图与高度箱线图。同时，对图像通道数进行了频次统计。




图 2 图像分辨率与存储特征分析

统计结果显示，图像的宽度和高度均值均非常接近 512 像素，且标准差极小。所有图像均为三通道 RGB 格式，尽管 MRI 本质上是单通道灰度成像，但数据源以三通道形式存储，这与后续的灰度转换并不冲突。统一的中心裁剪与缩放策略足以有效处理这一尺寸分布，本项目将输入尺寸固定为 **224×224** 像素。

3.3 随机样本视觉检查

首先从每个类别中抽取 5 张样本，在 4×5 的网格中进行展示，每张子图均标注其类别，同时设置随机种子 $SEED = 42$ 以保证可复现性。




图 3 样本网格图

如图 3 所示，**glioma**（胶质瘤）常表现为弥漫性、不规则的高信号区域，边界模糊，与周围正常组织呈浸润性过渡。**meningioma**（脑膜瘤）多为圆形或类圆形占位，边界清晰锐利。**pituitary**（垂体瘤）病灶集中于蝶鞍区，表现为垂体区域的局部膨隆或不对称。**notumor**（正常）脑室结构对称，灰白质分界清晰，无任何异常占位或高信号病灶。这些显著的视觉区分度初步证明，基于图像纹理与形态特征的分类模型是具备可行性的。

3.4 像素级空间统计分析

为了揭示各类肿瘤的典型空间分布模式，我们进行了像素级的聚集分析。我们对每个类别随机选取最多 20 张图像，统一缩放至 128×128 的灰度图。随后，按式 3.1 和式 3.2 逐像素计算均值和标准差两个统计量。

$$\mu_c(x, y) = \frac{1}{N_c} \sum_{i=1}^{N_c} I_i(x, y) \quad (3.1)$$

$$\sigma_c(x, y) = \sqrt{\frac{1}{N_c - 1} \sum_{i=1}^{N_c} [I_i(x, y) - \mu_c(x, y)]^2} \quad (3.2)$$




图 4 空间统计图

均值图揭示了不同类别病灶的“平均”解剖位置和典型形态。例如，`pituitary` 类的均值图在图像中央底部显示明显的亮斑聚集；而 `glioma` 类的均值图则呈现出更弥散、非对称的亮度分布。

标准差图的高值区域通常对应于肿瘤的边界或形态变异较大的区域，这提示在这些区域，纹理特征可能具有较强的类内差异性。

四、数据预处理与特征工程（高维杰）

基于以上探索性分析的结论，我们构建了一套完整的数据预处理与特征工程流水线，其输出直接服务于后续模型训练与对比实验。

4.1 标准图像预处理流水线

为了消除无关噪声、增强关键结构并统一输入格式，每张原始图像在送入模型之前，都会按顺序经历以下标准化预处理步骤。下图展示了单个样本经过完整预处理前后的对比效果：




图 5 预处理前后对比图

步骤一：尺寸标准化

我们采用双三次插值算法将所有输入图像统一缩放至 224×224 像素的空间维度。该尺寸是 ResNet 等主流 CNN 架构的经典输入尺寸，同时 224×224 在计算开销与空间信息保留之间取得了良好的平衡，相较于 512×512 将计算量降低至约五分之一，显著缩短了训练时间，且该分辨率足以保留肿瘤区域的关键形态与纹理特征。此外，双三次插值算法在缩放过程中能够较好地保持边缘平滑度，避免引入不必要的锯齿伪影。

步骤二：值域归一化

原始 JPG 图像的像素值为 $[0, 255]$ 的 8 位整数，直接输入神经网络会引发数值优化问题。因此，我们将所有像素值除以 255.0，映射至 $[0.0, 1.0]$ 的浮点数区间。通过归一化操作，各通道处于统一量级，避免了梯度更新步长不一致及激活函数饱和导致的梯度消失问题，同时确保网络各层的输入分布处于激活函数的敏感工作范围内，有效加速了模型收敛并提高了训练的数值稳定性。

步骤三：色彩空间转换

脑部 MRI 本质为单通道的灰度图像，尽管四个数据源均以三通道 RGB 格式存储图像，但其中的彩色信息并非源于真实的色彩采集，而是将灰度数据复制到三个通道的伪彩色存储方式。因此我们采用加权平均公式 $I_{gray}(x, y) = 0.299 \times R(x, y) + 0.587 \times G(x, y) + 0.114 \times B(x, y)$ (式 4.1) 将彩色图像转换为单通道灰度图。该转换

消除了三个通道间的冗余信息，使后续处理更加聚焦于真实的图像结构；同时将数据量压缩为原来的三分之一，降低了计算复杂度；同时，灰度格式兼容 CLAHE、HOG、LBP 等经典算法的输入要求，便于后续特征提取与增强操作。

步骤四：平滑去噪（高斯滤波）

MRI 图像在采集过程中易受到多种噪声源的污染，其中最主要的是由人体组织和电子设备热运动引起的高斯噪声。因此我们采用二维高斯核对图像进行低通滤波平滑，高斯核函数为 $G(x,y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$, $\sigma = 0.5$ (式 4.2)。核尺寸为 5×5 ，这能够在去除高频噪声的同时保留图像中肿瘤边界、组织结构等关键的低频边缘信息，避免过度平滑导致图像模糊和细节丢失。

步骤五：中值滤波

针对 MRI 图像中可能存在的椒盐噪声，我们采用中值滤波进行处理。对每个像素取其 3×3 邻域内所有像素值的中位数作为该像素的新值。与高斯滤波等线性平滑滤波器不同，中值滤波是一种非线性滤波方法，其核心优势在于当 3×3 邻域内存在极亮或极暗的孤立噪声点时，中值操作会将其排除在输出结果之外，从而在有效去除椒盐噪声的同时不会对图像边缘产生模糊效应。

步骤六：对比度自适应增强（CLAHE）

针对脑部 MRI 图像对比度不足、肿瘤与正常组织灰度差异小的问题，我们应用限制对比度自适应直方图均衡化算法，设置截断限幅 $\text{clip_limit} = 0.01$ 、网格划分为 8×8 。该算法在各局部网格区域内独立执行直方图均衡化以实现局部对比度提升；同时，限制任意灰度级在直方图中的最大占比不超过 1%，防止因直方图过度集中而导致的噪声过度放大；各子区域之间的边界通过双线性插值进行平滑过渡，避免出现块状伪影。经过 CLAHE 增强后，MRI 图像中原本模糊的肿瘤区域与正常组织的边界变得清晰可辨，肿瘤内部的结构异质性也更加突出，这为后续的模式训练和手工特征提取提供了高质量的输入。

步骤七：通道重构

经过上述预处理，图像已转换为增强后的高质量灰度图，ResNet 等主流深度模型基于 ImageNet 三通道彩色图像预训练，其输入层固定接受三通道数据，因此我们将单通道灰度图在通道维度上进行三次复制，重构为三通道 RGB 图像，其数学形式

为 $I_{out}(x,y)=[I_{gray}(x,y),I_{gray}(x,y),I_{gray}(x,y)]$ (式4.3)。虽然修改网络结构的第一层卷积核权重以适配单通道输入也是一种可行方案，但这样会丧失预训练权重的优势。采用灰度复制策略虽未在通道维度引入新信息，却能有效利用迁移学习，显著提升训练效率与分类精度。

4.2 数据集分层划分策略

为了获得具有统计意义的模型性能评估，我们采用严格的分层抽样策略，按 **70% : 15% : 15%** 的比例将全部数据划分为互不重叠的训练集、验证集和测试集。各类别在各子集中的分布情况如下表所示，验证了划分操作成功保持了原始约 27.5%、20.6%、29.2%、22.7% 的分布比例。

划分集	glioma	meningioma	notumor	pituitary	合计
训练集	2,220	1,666	2,362	1,830	8,078
验证集	475	357	506	393	1,731
测试集	476	357	506	392	1,731
总计	3,171	2,380	3,374	2,615	11,540

4.3 数据在线增强策略

为提升模型的泛化能力并防止过拟合，我们在训练中采用动态在线数据增强，每次迭代对当前批次图像施加随机变换：

- (1) **几何变换**：以 50% 概率进行水平/垂直翻转；在 $[-54^{\circ}, +54^{\circ}]$ 范围内随机旋转；水平和垂直方向各施加 $[-10\%, +10\%]$ 的随机平移。
- (2) **色彩变换**：在 $[0.9, 1.1]$ 范围内随机调整图像对比度，模拟不同 MRI 扫描设备的窗宽/窗位差异。
- (3) **混合增强**：对于同一批次内的随机两个样本 (x_i, y_i) 和 (x_j, y_j) ，从 $\text{Beta}(0.2, 0.2)$ 分布中采样混合系数 λ ，构造新的样本：

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda)y_j \tag{4.4}$$




图 6 混合增强样本

4.4 特征提取工程

我们从预处理后的图像中提取了一组 **406 维手工特征**。该特征向量融合了图像的全局形状、局部纹理和统计特性，构成如下：

特征组	算法	特征 维度	核心原理与医学关联
方向梯度直方图	HOG	392	将图像划分为 7×7 个 32×32 像素的单元，每个单元统计 8 个方向的梯度幅值直方图。特征维度计算： $7 \times 7 \times 1 \times 1 \times 8 = 392$ 。该特征对肿瘤的边界形状和边缘方向高度敏感。
局部二值模式	LBP	10	对每个像素，比较其与半径为 1 的 8 个邻域像素的灰度值，生成 8 位二进制模式，统计均匀模式（跳变次数 ≤ 2 ）的直方图，划分为 10 个区间。该特征能有效描述 MRI 图像的微观组织纹理差异。
灰度共生矩阵	GLCM	4	计算距离为 1、方向为 0° 的共生矩阵，并从中提取四个经典统计量：对比度、同质性、能量和相关性。这些特征从宏观层面描述了灰度的空间分布规律。

为评估特征的判别能力，对训练集特征执行了 **PCA 主成分分析**和 **t-SNE t 分布随机邻域嵌入**两种降维算法，将 406 维投影至二维平面并绘制散点图。




图 7 特征降维投影

五、机器学习模型原理介绍

5.1 GKLNN (Gaussian Kernel Liquid Neural Network) (高维杰)

该模型不依赖 ImageNet 迁移学习，而是采用“手工特征提取 + 液态神经网络”的技术路线，旨在无预训练权重的约束下，通过更强的特征工程与液态动力学建模逼近深度 CNN 的分类性能，同时保持可控的推理延迟，满足临床辅助诊断场景对实时性与可解释性的双重需求。

与 ResNet50V2、ConvNeXtTiny 等直接在像素空间做卷积的模型不同，GKLNN 从 MRI 图像中提取可解释的纹理特征 (HOG/LBP/GLCM)，经 PCA 降维后与原始 406 维特征构成双路输入，再通过高斯核原型匹配与液态储备池建模非线性动态，最后经门控融合与 MLP 分类头输出四类别 softmax 概率。

5.1.1 整体架构设计




图 8 GKLNN 架构设计

5.1.2 高斯核液态层核心原理

对输入 PCA 向量 $\mathbf{x} \in \mathbb{R}^{160}$ 与第 k 个原型 $\mathbf{p}_k$ ，计算平方欧氏距离并施加 **5 个尺度** 的高斯核，共产生 $2400 \times 5 = 12000$ 维核特征向量 $\kappa(\mathbf{x})$

$$\kappa_{k,s}(\mathbf{x}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{p}_k\|_2^2}{2(\sigma \cdot s)^2}\right), s \in \{0.25, 0.5, 1.0, 2.0, 4.0\} \quad (5.1)$$

小尺度 $s = 0.25, 0.5$ 时对局部特征敏感，能捕捉细粒度的类内差异。 $s = 1.0$ 是基准尺度，匹配全局特征分布。**大尺度** $s = 2.0, 4.0$ 能感知更宽泛的特征邻近关系，

捕获类别间的宏观结构。这种多尺度设计使模型同时具备局部精确匹配与全局结构感知的能力，类似于卷积神经网络中多尺度感受野的设计思想。

5.1.3 三储备池并行集成

使用 3 个独立随机种子（42/ 137/ 271）初始化三套储备池，谱半径依次递减。

储备池	随机种子	谱半径 ρ	设计意图
Liquid-1	42	0.85	较大记忆容量，捕获较长时间依赖
Liquid-2	137	0.81	中等记忆容量，平衡动态与稳定性
Liquid-3	271	0.77	较小记忆容量，侧重短期精确响应

不同储备池因随机初始化与谱半径差异，捕获不同时间尺度与动态模式，形成集成储备池（Ensemble Reservoir）效应，提升模型整体的表达能力与鲁棒性。

5.1.4 分支结构与门控融合机制

除三个液态储备池外，模型还包含两条 MLP 分支。

分支	结构	输出维度	设计意图
PCA Branch	Dense(128, ReLU) +BatchNorm	128	从压缩特征中提取全局结构模式
Raw Branch	Dense(320)→BN→ Dropout(0.2)→Dense(160)→BN	160	从完整纹理特征中捕获细节信息

每个全连接层后接 **BatchNorm**，通过将激活值标准化至均值为 0、方差为 1 的分布，有效缓解内部协变量偏移问题，加速训练收敛。同时，以 0.2 的概率 **Dropout** 神经元输出，增强泛化能力，防止过拟合。

5.2 ViT（Vision Transformer）（申英辰）

Vision Transformer（ViT）由 Dosovitskiy 等人在《An Image is Worth 16×16 Words》中提出，核心思想是把图像切分成一系列固定大小的图像块（patch），将其视为类似自然语言中的词序列，再直接套用标准 Transformer 编码器进行建模。与卷积神经网络（CNN）依赖局部感受野、平移等变性等强归纳偏置不同，ViT 几乎不引入这类先验，而是让自注意力机制在全局范围内自由建模任意两个 patch 之间的关系。这带来

了更强的全局建模能力，但也意味着 ViT 对数据量更敏感——在大规模数据上预训练往往是发挥其性能的关键。

5.2.1 整体架构

ViT 的前向流程可以概括为「切块 → 线性投影 → 加位置编码 → Transformer 编码器 → 取表示 → 分类头」六个环节：输入图像先被均匀切分为若干互不重叠的 patch；每个 patch 展平后经线性投影映射为固定维度的 token 向量（Patch Embedding）；随后为所有 token 叠加可学习的位置编码，并在序列首部拼接一个可学习的分类标记（CLS token，部分实现改用全局平均池化）；这组 token 依次通过 L 层结构相同的 Transformer 编码器；最后取 CLS token（或池化结果）送入 MLP 分类头，输出各类别的预测概率。下图给出了 ViT 的整体结构与单个 Transformer 编码器块的内部构造。




图 9 Vision Transformer 整体架构

5.2.2 Patch Embedding 与序列化

设输入图像张量为 $[C, H, W]$ ，patch 边长为 P ，则图像被切分为 $N = (H \times W)/P^2$ 个 patch。每个 patch 含 $P^2 \cdot C$ 个像素值，展平后通过一个线性层投影到 D 维，得到该 patch 的 token 表示。工程上这一步通常等价实现为一个卷积： $\text{Conv2d}(C \rightarrow D, \text{kernel} = P, \text{stride} = P)$ ，卷积核不重叠地扫过整幅图，输出通道数即为嵌入维度 D 。

以标准 ViT-Base 为例：输入 224×224 、 $P = 16$ ，得到 $N = 196$ 个 patch，嵌入维度 $D = 768$ ；我们自建的小型 ViT 针对 CIFAR-100 的 32×32 原生输入，取 $P = 4$ ，得到 $N = 8 \times 8 = 64$ 个 patch，嵌入维度记为 `embed_dim`。经过 Patch Embedding 后得到形状为 $[B, N, D]$ 的 token 张量；再叠加形状为 $[1, N, D]$ （若使用 CLS token 则为 $[1, N + 1, D]$ ）的可学习位置编码，为模型注入 patch 的空间顺序信息。

5.2.3 Transformer 编码器：多头自注意力与 MLP

每个编码器块采用 Pre-LN（前置层归一化）结构，前向可写为两条带残差的支路： $x = x + \text{MHSA}(\text{LN}(x))$ 与 $x = x + \text{MLP}(\text{LN}(x))$ 。Pre-LN 把层归一化放在子模块之前、残差相加放在最外层，使得从输出到输入始终保留一条「恒等直连」通路，梯度可以几乎无衰减地回传，有效缓解深层网络的梯度消失问题，训练更稳定，这也是本实验能够把自建 ViT 堆叠到 24 层仍可正常收敛的原因。

多头自注意力（MHSA）。输入 token 张量 $x \in \mathbb{R}^{B \times N \times D}$ 分别经三个线性层得到查询、键、值： $Q = xW_Q, K = xW_K, V = xW_V$ ，形状均为 $[B, N, D]$ 。将 D 维按头数 h 拆分为 h 个子空间，每个头维度 $d_k = D/h$ ，逐头计算缩放点积注意力：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中 QK^T 是形状为 $[B, h, N, N]$ 的注意力矩阵，刻画了每个 patch 对其余所有 patch 的关注权重；除以 $\sqrt{d_k}$ 是为了抑制点积随维度增大而方差过大、导致 softmax 梯度过小的问题。各头输出在通道维拼接回 $[B, N, D]$ ，再经输出投影 W_O 。以自建配置 $\text{dim}=64, \text{heads}=2$ 为例， $d_k = 32$ ，注意力矩阵尺寸为 64×64 （patch 数 $\times$ patch 数）。

MLP（前馈网络）。结构为 $\text{Linear}(D \rightarrow r \cdot D) \rightarrow \text{GELU} \rightarrow \text{Linear}(r \cdot D \rightarrow D)$ ，先升维再降维，中间用 GELU 激活引入非线性。扩张比 r 是重要超参：标准 ViT-Base 取 $r = 4$ ；自建的小型 ViT 为控制参数量取 $r = 2$ （如 $64 \rightarrow 128 \rightarrow 64$ ）。

5.2.4 特征聚合与分类头

Transformer 编码器输出后需要把 N 个 token 聚合为一个全局表示，常见两种方式：一是使用序列首部的 CLS token 作为整图表示（ViT 原论文做法）；二是对所有 patch token 做全局平均池化（GAP，即 $x.\text{mean}(\text{dim}=1)$ ）。本人自建 ViT 采用 GAP，省去了 CLS token，结构更简洁且对小数据更友好。最终由分类头 $\text{Linear}(D \rightarrow \text{num_classes})$ 输出各类别 logits，配合交叉熵损失（含 label smoothing）进行训练。

5.2.5 预训练与迁移学习

由于 ViT 缺乏 CNN 的局部性与平移等变性等归纳偏置，在中小规模数据集上从随机初始化直接训练往往难以收敛到理想精度；而在超大规模数据集上预训练后再迁移，则能显著释放其性能。本部分使用的 ViT-Base 在 ImageNet-21k（约 1400 万张

图像、21843 个类别）上完成预训练，学到了通用且可迁移的视觉特征。迁移时的标准做法是：保留预训练主干权重，仅将分类头替换为目标任务的类别数，并以较小的学习率对整个网络进行微调（**fine-tune**）。这一「大规模预训练 + 小学习率微调」的范式，正是本部分在医学图像分类任务上取得高精度的理论依据，也与后文「从头训练效果明显更差」的对照实验形成呼应。

5.3 ResNet50V2（段皓阳）

该模型在深层卷积网络中引入残差连接，并通过预激活结构改善梯度传播，适合提取 MRI 图像中的纹理、边界、形态和组织结构特征。

5.3.1 残差学习原理

普通深层网络在层数增加后容易出现梯度消失和网络退化。ResNet 不直接学习目标映射 $H(x)$ ，而是学习残差 $F(x) = H(x) - x$ ，并通过捷径连接得到 $H(x) = F(x) + x$ 。恒等映射为信息和梯度提供了直接通路，使网络即使达到 50 层仍能够稳定优化。

5.3.2 ResNet50V2 预激活结构

ResNet50V2 将残差分支调整为“批量归一化—ReLU—卷积”的预激活顺序，使非线性运算位于卷积之前，减少捷径连接上的信息阻断。主干网络由多个瓶颈残差模块组成，每个模块利用 1×1 、 3×3 和 1×1 卷积完成通道压缩、空间特征提取与通道恢复，在控制计算量的同时形成多层次视觉表征。




图 10 本实验 ResNet50V2 模型架构

5.3.3 迁移学习与分类头

模型加载 ImageNet 预训练权重并移除原始分类层。预训练主干提供通用边缘、纹理和形状特征，本实验再使用全局平均池化和两层全连接网络完成四分类。分类头依次为 Dense(256, ReLU, L2)、Batch Normalization、Dropout(0.3)、Dense(128, ReLU, L2)、Dropout(0.2)和 Dense(4, Softmax)。模型输入为 $224 \times 224 \times 3$ ，总参数量为 24,123,780。

5.4 DeepSCNN（张益恺）

DeepSCNN 是面向本项目脑部 MRI 四分类任务设计的双视图卷积神经网络。其核心由数据增强与预处理、Siamese 双视图、共享 ResNet50V2 编码器、SE 通道注意力、空间注意力、多关系特征融合和多层分类头组成。模型总参数量为 26,110,951。




图 11 DeepSCNN 整体架构

5.4.1 共享 ResNet50V2 编码器

ResNet50V2 通过预激活残差单元建立稳定的深层特征提取路径。项目加载 ImageNet 预训练权重并移除原始分类头，使主干输出二维特征图。迁移学习阶段仅解冻主干最后 50 层，以较小学习率微调，从而在保留通用视觉先验的同时适应脑部 MRI 纹理。

5.4.2 通道注意力与空间注意力

SE 通道注意力先对特征图进行全局平均池化，再经两层全连接网络生成 $0 \sim 1$ 的通道权重，并与原特征逐通道相乘，使模型强化与肿瘤相关的语义通道。空间注意力则对通道维分别计算平均值和最大值，将二者拼接后通过 7×7 卷积生成空间权重图，用于突出病灶区域并抑制无关背景。

5.4.3 双视图与多关系融合

原始视图和水平翻转视图经共享编码器得到两个 256 维特征向量 $\mathbf{a}$ 与 $\mathbf{b}$ 。融合层不仅拼接 $\mathbf{a}$ 、 $\mathbf{b}$ ，还计算绝对差 $|\mathbf{a}-\mathbf{b}|$ 、逐元素乘积 $\mathbf{a}\odot\mathbf{b}$ 和余弦相似度 $\cos(\mathbf{a},\mathbf{b})$ 。其中，原始特征保留各视图信息，差异项刻画方向变化，乘积项强调共同激活，余弦相似度反映整体一致性。

5.4.4 分类头与正则化

融合向量依次通过 384 维和 128 维全连接层，并配合 Batch Normalization、Dropout (0.35 与 0.20) 及 $L2=10^{-4}$ 权重正则化；最终由 4 维 Softmax 层输出各类别概率。编码器内部的 256 维全连接层还使用 0.25 Dropout，以降低高维特征过拟合。

5.5 ConvNeXt Tiny (周艺涵)

ConvNeXt 是 Liu 等人在论文《A ConvNet for the 2020s》中提出的 Modern CNN 模型。该模型并未放弃卷积结构，而是在传统 CNN 的层级特征表达基础上，吸收了视觉 Transformer 时代的一些有效设计思想，例如 patchify stem、较大的深度可分离卷积核、倒置瓶颈结构、Layer Normalization、GELU 激活以及残差连接等。其核心目标是在保持卷积网络局部建模和层级归纳偏置优势的同时，提高网络对复杂图像语义特征的表达能力。

从算法角度看，ConvNeXt 属于层级式特征提取模型。输入图像首先经过 Stem 模块被划分为低分辨率特征图，随后依次通过四个 Stage。随着 Stage 的加深，特征图的空间尺寸逐步减小，通道数逐步增加；浅层更偏向捕获边缘、纹理和灰度变化，深层则将局部线索组合为更抽象的形态结构和语义表征。最终，分类头将高层特征映射为各类别的预测分数。

5.5.1 ConvNeXt Block 的基本结构

ConvNeXt 的主体由多个 ConvNeXt Block 堆叠而成。一个典型 Block 首先使用 7×7 深度卷积 (Depthwise Convolution) 扩大局部感受野，使每个通道在较大邻域内整合空间信息；随后使用 Layer Normalization 稳定特征分布；再通过两个 1×1 线性映射形成倒置瓶颈结构，即先将通道维度扩展到约 4 倍，再经 GELU 非线性激活后压缩回原通道数。Block 末端通常带有 Layer Scale、Drop Path 和残差连接，使网络在加深时仍能保持较稳定的梯度传播。

若将输入特征记为 $\mathbf{x}$ ，则一个 ConvNeXt Block 可抽象为 $\mathbf{y} = \mathbf{x} + \mathbf{F}(\mathbf{x})$ 。其中 $\mathbf{F}(\mathbf{x})$ 表示深度卷积、归一化、通道扩展、非线性激活和通道压缩等操作的组合。残差连

接使 Block 不必重新学习全部特征，而是在原有特征的基础上学习增量表示，这也是深层视觉网络能够稳定训练的重要原因。

5.5.2 ConvNeXt Tiny 的层级架构

ConvNeXt Tiny 是 ConvNeXt 家族中规模较小的一种配置，其通道宽度依次为 96、192、384、768，四个 Stage 中 Block 数量分别为 3、3、9、3。对于 224×224 的三通道图像，其主干网络可以表示为如下层级结构：

- (1) Stem: Patchify 卷积, Conv2d(kernel=4, stride=4), $[3, 224, 224] \rightarrow [96, 56, 56]$ 。
- (2) Stage 1: ConvNeXt Block $\times 3$, 空间尺寸不变, $[96, 56, 56] \rightarrow [96, 56, 56]$ 。
- (3) Downsample: LayerNorm+ Conv2d(kernel=2, stride=2), $[96, 56, 56] \rightarrow [192, 28, 28]$ 。
- (4) Stage 2: ConvNeXt Block $\times 3$, $[192, 28, 28] \rightarrow [192, 28, 28]$ 。
- (5) Downsample: LayerNorm+Conv2d(kernel=2, stride=2), $[192, 28, 28] \rightarrow [384, 14, 14]$ 。
- (6) Stage 3: ConvNeXt Block $\times 9$, $[384, 14, 14] \rightarrow [384, 14, 14]$ 。
- (7) Downsample: LayerNorm+ Conv2d(kernel=2, stride=2), $[384, 14, 14] \rightarrow [768, 7, 7]$ 。
- (8) Stage 4: ConvNeXt Block $\times 3$, 形成高层语义特征, $[768, 7, 7] \rightarrow [768, 7, 7]$ 。
- (9) Head: Global Average Pooling + LayerNorm + Linear, $[768, 7, 7] \rightarrow [768] \rightarrow [\text{classes}]$ 。

上述结构体现了典型卷积网络的“空间压缩、通道扩展”规律：网络越靠后，特征图的高和宽越小，但通道数越多。这种设计使模型在浅层保留局部细节，在深层聚合更大范围的上下文信息。Stage 3 具有 9 个 ConvNeXt Block，是 ConvNeXt Tiny 中深度最大的部分，通常承担更充分的高级特征建模任务。

5.5.3 分类头与输出形式

主干网络输出的高层特征维度为 $[768, 7, 7]$ 。分类头首先通过全局平均池化（Global Average Pooling）将每个通道的空间响应汇总为一个数值，从而得到 768 维特征向量；随后使用 Layer Normalization 对特征分布进行规范化；最后通过全连接层 Linear 将 768 维特征映射为 num_classes 维输出。该输出通常称为 logits，经过 Softmax 后可转化为各类别的概率分布。

因此，ConvNeXt Tiny 的整体计算流程可以概括为： $[3, 224, 224] \rightarrow \text{Stem} \rightarrow \text{Stage 1} \rightarrow \text{Downsample} \rightarrow \text{Stage 2} \rightarrow \text{Downsample} \rightarrow \text{Stage 3} \rightarrow \text{Downsample} \rightarrow \text{Stage 4} \rightarrow \text{Global Average Pooling} \rightarrow \text{LayerNorm} \rightarrow \text{Linear} \rightarrow [\text{num_classes}]$ 。这一结构既保留了

CNN 对局部纹理和空间邻域的建模能力，又通过较深的层级堆叠获得了对复杂形态和全局语义的表达能力。

5.5.4 与经典 CNN 思路的关系

与传统卷积神经网络相比，ConvNeXt 的基本思想仍然是通过卷积层逐级提取图像特征，但它在模块设计上更接近现代视觉模型：使用 patchify stem 代替较复杂的早期卷积堆叠，使用 7×7 深度卷积扩大感受野，使用倒置瓶颈结构增强通道表达，并将 Batch Normalization 替换为 Layer Normalization。这些设计使模型在保持卷积网络可解释层级结构的同时，具备更强的表征能力和更好的训练稳定性。

六、多模型训练

6.1 GKLNN（高维杰）

6.1.1 特征空间 Mixup 与 CutMix 增强

由于模型输入为特征向量，Mixup 和 CutMix 增强操作在 PCA + Raw 特征空间进行。在医学影像数据中，不同类别之间可能存在形态上的渐变过渡。增强操作使模型学习到类别间的连续映射，而非硬性的决策边界，更贴近临床诊断中肿瘤类型之间存在谱系连续性的实际情况。

6.1.2 损失函数

使用类别交叉熵损失 $\mathcal{L} = -\sum_{c=1}^4 \tilde{y}_c \log(\hat{y}_c)$ ，其中 $\tilde{y}_c$ 为标签平滑后的目标分布：

$$\tilde{y}_c = \begin{cases} 1 - \epsilon + \epsilon/4, & c = \text{真实类别} \\ \epsilon/4, & c \neq \text{真实类别} \end{cases}$$

标签平滑通过将 one-hot 目标替换为均匀分布的加权组合，提升泛化能力。

6.1.3 优化器与学习率调度

(1) 优化器

使用 Adam 优化器， $\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \nabla_{\theta} \mathcal{L}_t$ ， $\beta_1 = 0.9$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) (\nabla_{\theta} \mathcal{L}_t)^2, \beta_2 = 0.999$$

$$\theta_{t+1} = \theta_t - \eta \cdot \frac{\mathbf{m}_t}{\sqrt{\mathbf{v}_t} + \epsilon}, \epsilon = 10^{-7}$$

(2) 余弦退火学习率调度

采用余弦退火策略，将学习率从初始值平滑衰减至最小值：

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \frac{\pi t}{T}\right)$$

其中 $\eta_{\max} = 2 \times 10^{-4}$ ， $\eta_{\min} = 2 \times 10^{-6}$ ， $T = 180$ 为总轮数， t 为当前轮次。

余弦退火的优势在于：**前期学习率较高**加速收敛；**中期平滑衰减**稳定优化过程；**后期学习率较低**精细调参，避免在最优解附近震荡。




图 12 GKLNN 训练集与验证集准确率曲线

6.2 ViT（申英辰）

6.2.1 实验总体设计

我们围绕 ViT 设计了两组实验，共同回答两个问题：一是「小型 ViT 从头训练时，模型容量（宽度、深度）如何影响拟合与泛化」；二是「预训练与数据集规模，对 ViT 的最终精度到底有多大影响」。三条主线如下：

- 主线 A | ViT-Base，医学图像数据集，迁移学习与从头训练。采用在 ImageNet-21k 上预训练的 ViT-Base，替换分类头后在医学图像分类数据集上做小学习率微调，作为本部分的主力模型。

- 主线 B | 自建 Standard ViT，CIFAR-100，从头训练。ViT-Base，迁移学习。自行实现标准 Pre-LN ViT，在 CIFAR-100 原生 32×32 输入上系统对比不同嵌入维度（dim=48/64/96/128）与深度（12/24 层）的表现，并进一步考察 dropout 与强数据增强的正则化效果。

6.2.2 ViT-Base 迁移学习训练配置（医学图像数据集）

主力模型选用在 ImageNet-21k 上预训练的 ViT-Base/16：输入 224×224、patch 16×16（196 个 patch + 1 个 CLS token）、嵌入维度 768、12 层编码器、12 个注意力头（head dim 64）、MLP ratio 4，参数量约 86M。迁移时保留预训练主干权重，仅将分类头替换为医学数据集的类别数，随后对整个网络进行小学习率微调。对比模型则从头训练，作为对比。

6.2.3 自建 Standard ViT 训练配置（CIFAR-100，从头训练）

自建模型采用标准 Pre-LN Transformer 结构，Patch Embedding 用 Conv2d(3→embed_dim, kernel=4, stride=4) 将 32×32 图像切为 8×8=64 个 token，不使用 CLS token，改用全局平均池化聚合特征。仅嵌入维度、深度、头数随各配置变化。对比模型采用 ViT-Base 进行迁移学习,为了适配 ViT-Base 的输入维度，我们将原始图像大小从 32×32 上采样到 224×224。

6.3 ResNet50V2（段皓阳）

6.3.1 实验配置

ResNet50V2 训练采用 Adam 优化器和带 0.05 标签平滑的分类交叉熵，以验证集准确率选择最佳模型。主要参数如下：

参数	实际设置
输入	224×224×3；4 类；batch size=16
损失	Adam；分类交叉熵；label smoothing=0.05
冻结	冻结主干，12 轮，学习率 0.001
微调	解冻顶部 40 层，20 轮，学习率 0.0001
正则	L2=1×10 ⁻⁴ ；Dropout=0.3/0.2；翻转与旋转
测试	监控 val_accuracy；5 次 TTA；扰动标准差 0.01

6.3.2 两阶段训练过程

第一阶段冻结 ResNet50V2 主干，只训练新增分类头，共训练 12 epoch。第二阶段加载第一阶段最佳权重，解冻主干顶部 40 层并将学习率降低至 0.0001，共训练 20 epoch。

训练过程中使用 EarlyStopping、ModelCheckpoint 和 ReduceLROnPlateau。前两者用于恢复并保存验证集准确率最高的权重，后者在性能进入平台期时按 0.5 比例降低学习率，最低学习率为 1×10^{-7} 。输入端使用随机水平翻转和 0.05 因子的随机旋转，后者对应最大约 $\pm 18^\circ$ 。




图 13 ResNet50V2 训练集与验证集准确率曲线

6.3.3 训练曲线分析

第一阶段验证准确率由 85.21% 提高至 91.16%。进入微调阶段后，验证准确率继续提升，在总第 31 轮达到最高值约 97.00%。最后一轮训练准确率为 99.74%，验证准确率为 96.48%，二者存在约 3 个百分点差距，表明后期出现轻度过拟合，但验证集性能整体保持稳定。

6.4 DeepSCNN（张益恺）

6.4.1 实验总体设计

实验采用 ImageNet-ResNet50V2 预训练权重，并从已完成的第一阶段权重继续第二阶段微调。第二阶段解冻主干最后 50 层，训练 30 epoch，初始学习率为 5×10^{-5} ，批量大小默认 16。训练过程中按验证准确率保存最佳模型，并结合 EarlyStopping 和 ReduceLROnPlateau 控制收敛。

项目	配置
----	----

模型	DeepSCNN-BrainAttention_v3
骨干网络	ImageNet 预训练 ResNet50V2
第二阶段	解冻最后 50 层，30 epoch
优化器	Adam，初始学习率 5×10^{-5}
损失函数	交叉熵 + label smoothing 0.05
正则化	L2= 10^{-4} ；Dropout 0.25/0.35/0.20
模型选择	监控 val_accuracy，保存最佳 checkpoint

6.4.2 训练收敛情况

训练历史共记录 30 epoch。训练准确率从 88.04% 上升到 99.98%，验证准确率从 91.68% 上升并在第 27~28 epoch 达到 96.71%。验证损失最低约为 0.359，后期在 0.36 左右波动。第 22 epoch 后学习率由 5×10^{-5} 下调至 2.5×10^{-5} ，第 26 epoch 后进一步降至 1.25×10^{-5} 。




图 14 DeepSCNN 训练集与验证集准确率曲线

6.5 ConvNeXt Tiny（周艺涵）

6.5.1 实验总体设计

本次实验围绕 ConvNeXt Tiny 主线展开。训练脚本 train_convnext_tiny.py 读取 config 中的参数，依次完成数据集读取、模型创建、预训练权重加载、训练、验证、历史记录保存和最佳检查点保存。

训练集用于模型学习，验证集用于每个 epoch 后评估模型表现。当验证准确率超过历史最好值时，程序保存 best.pt。本次训练中验证集最高准确率达到 97.57%。

6.5.2 训练配置

配置文件中模型名称为 convnext_tiny，类别数为 4，输入尺寸为 224。训练轮数为 30，batch_size 为 16，eval_batch_size 为 32，初始学习率为 0.0001，最小学习率为 0.000001，weight_decay 为 0.05，随机种子为 42。

训练时使用 processed/train 和 processed/val 两部分数据。训练集随机输入模型，验证集保持固定顺序，便于稳定评估。训练过程中每轮都会记录 train_loss、train_acc、val_loss、val_acc 和学习率，并保存 last.pt 与 best.pt。

七、实验结果分析

7.1 GKLNN（高维杰）

7.1.1 评估指标

Accuracy	Precision	Recall	F1-Score	ROC-AUC	Cohen's Kappa	MCC	Params	Inference Latency (ms)
0.938	0.938	0.938	0.938	0.987	0.917	0.917	32478276	13.14605

7.1.2 各类别详细性能

类别	Precision	Recall	F1-Score
glioma	91.16%	93.49%	92.31%
meningioma	88.30%	86.83%	87.56%
notumor	97.22%	96.84%	97.03%
pituitary	98.67%	98.47%	98.57%

pituitary（垂体瘤）与 notumor（正常）表现最优，F1-Score 分别达 98.57%和 97.03%。垂体瘤因解剖位置固定，形态特征稳定，易于与其它类别区分；正常脑组织因结构对称、无明显占位，同样易于识别。

glioma（胶质瘤）表现良好，F1-Score 达 92.31%。胶质瘤的浸润性生长模式虽增加了一定的分类难度，但 HOG 特征对边界模糊程度的刻画有效支撑了判别。

meningioma（脑膜瘤）表现相对较弱，F1-Score 为 87.56%，召回率仅 86.83%。主要原因在于脑膜瘤的部分亚型在影像上与胶质瘤存在重叠，且当肿瘤体积较小时容易与正常组织混淆。

7.1.3 混淆矩阵




图 15 混淆矩阵

7.1.4 Grad-CAM++分支归因

通过对门控融合层计算梯度并按 Grad-CAM++公式聚合到五个分支，得到各分支的相对贡献率（以 glioma 类样本为基准）：




图 16 Grad-CAM++分支归因柱状图、

由图 16 可知，三个液态储备池合计贡献约 78.8%，是模型决策的绝对主导力量，验证了高斯核原型匹配+液态动力学设计的有效性。PCA 分支贡献 13.9%，提供全局降维结构信息的补充。

7.1.5 误差分析与改进方向

（1）最大混淆对 glioma ↔ meningioma（41 例，占 38.3%）。两者均为颅内实质性肿瘤，MRI 信号特征存在天然重叠。后续结合肿瘤位置先验（胶质瘤多发于幕上脑实质，脑膜瘤多发于脑表面或颅底），或引入多序列 MRI（T1 增强、T2-FLAIR、ADC）联合判别。

（2）meningioma 是最易误判类别。小型脑膜瘤与正常组织纹理相近，后续可增加更细粒度的 GLCM/LBP 特征或引入多尺度特征金字塔捕获不同大小肿瘤的纹理模式。

7.2 ViT（申英辰）

ViT 在是否使用预训练参数的情况下的得分对比：

配置	参数量	预训练	TrainAcc	ValAcc	TestAcc	现象
ViT-B/16, 224	85.876 M	是	99.96%	98.36%	98.47%	预训练迁移效果极强

ViT-B/16, 224	85.876 M	否	77.66%	79.73%	78.28%	同结构从头训练明显不足	
ViT-B/16, 224 与自搭小型 ViT 对比:							
配置	参数量	Depth	Heads	HeadDim	TrainAcc	ValAcc	TestAcc
dim=48	0.238M	12	3	16	55.17%	49.68%	49.04%
dim=48	0.465M	24	3	16	56.32%	48.12%	49.12%
dim=64	0.817M	24	2	32	65.15%	51.82%	51.64%
dim=96	1.816M	24	3	32	84.19%	52.90%	52.88%
dim=128	1.617M	12	2	64	89.22%	52.14%	52.11%
dim=128 + dropout0.1	1.617M	12	2	64	57.27%	57.34%	58.81%
ImageNet21k pretrained							
ViT-B + dropout0.1	85.876M	12	12	64	85.03%	90.14%	90.84%
no-pretrained							
ViT-B + dropout0.1	85.876M	12	12	64	99.48%	46.48%	46.87%

7.2.1 实验结果分析

(1) 预训练模型在两数据集上均远超从头训练

原因分析:

大规模预训练提供了高质量的参数初始化。ImageNet-21k 包含约 1400 万张图片、2 万多个类别，其数据规模和多样性远超 CIFAR-100（5 万张，100 类）和脑肿瘤数据集。ViT-B/16 在该数据上进行自监督或监督预训练后，其权重已经蕴含了丰富的通用视觉知识，这些知识具有极强的可迁移性。当模型迁移到下游任务时，其初始点已经位于一个良好的特征空间，而非从头训练时的随机位置。

从头训练遭遇“数据饥饿”。标准 ViT 本质上是 Transformer 架构，其核心机制——多头自注意力——需要通过大量数据来学习有效的注意力权重分布。

预训练模型的“免费”泛化增益。预训练模型在微调时，即使训练准确率并非完美（CIFAR-100 上为 85.03%），其验证准确率（90.14%）却能反超训练集，出现 Gap 为负（-5.11 pp）的现象。这印证了：预训练模型学到的特征具有天然的结构化先验，使其在下游任务上表现出超额的泛化能力，甚至不需要完全拟合训练集就能在验证集上取得优异表现。

（2）预训练模型在 CIFAR-100 上为何不如脑肿瘤数据集

原因分析：

任务难度差异：100 分类 vs 4 分类。CIFAR-100 要求模型在 100 个细粒度类别间进行区分，许多类别（如不同种类的交通工具、动物）之间视觉相似度较高，需要模型捕捉极其精细的纹理或形状差异。

输入分辨率不匹配。原始 32×32 图像仅包含 1024 个像素，上采样至 224×224 （50176 像素）后，新增的像素全部来自双线性插值，不包含任何真实的额外信息。模型看到的 224×224 图像实际上是“稀疏”的——大量像素只是原始 32×32 信息的平滑延伸，高频信息大量丢失。

（3）小型 ViT 依然不及预训练模型

原因分析：

数据规模不足。虽然自己搭建的小型 ViT 对 32×32 的图像进行了适配，但 CIFAR-100 仅有 5 万张训练图像，对于 ViT 这种依赖自注意力的架构而言，这远不足以学到通用且鲁棒的视觉特征。




图 17 混淆矩阵

7.3 ResNet50V2（段皓阳）

7.3.1 总体评价指标

测试集共包含 1731 个样本。模型正确分类 1678 个样本，误分类 53 个样本，总体准确率为 96.94%。加权 Precision、Recall 和 F1 均接近 0.97，说明模型在四个类别上的整体表现较为均衡。

评价指标	结果
Accuracy	0.9694
Precision（weighted）	0.9696
Recall（weighted）	0.9694
F1-Score（weighted）	0.9693
ROC-AUC（weighted, OvR）	0.9944
Cohen's Kappa	0.9589
MCC	0.9590

加权 ROC-AUC 达到 0.9944，说明模型具有很强的类别区分能力。Kappa 为 0.9589、MCC 为 0.9590，表明预测结果与真实标签高度一致，且总体性能并非由某一多数类别单独造成。

7.3.2 混淆矩阵与逐类误差




图 18 ResNet50V2 测试集混淆矩阵

类别	样本数 / 正确数 / P / R / F1
胶质瘤	476 / 457 / 0.9723 / 0.9601 / 0.9662
脑膜瘤	357 / 333 / 0.9652 / 0.9328 / 0.9487
无肿瘤	506 / 505 / 0.9546 / 0.9980 / 0.9758
垂体瘤	392 / 383 / 0.9897 / 0.9770 / 0.9833

无肿瘤类别召回率最高，506 个样本中 505 个被正确识别。垂体瘤精确率最高，为 98.97%。脑膜瘤召回率相对最低，为 93.28%；其错误主要流向胶质瘤和无肿瘤。胶质瘤也分别有 10 个和 9 个样本被误判为脑膜瘤和无肿瘤，说明胶质瘤与脑膜瘤的形态相似性、病灶面积和切片位置是主要混淆来源。

7.3.3 ROC 与 Precision-Recall 曲线




图 19 ResNet50V2 的 ROC 与 Precision-Recall 曲线

ROC 曲线整体靠近左上角，加权 AUC 为 0.9944；Precision-Recall 曲线在较大召回率范围内保持较高精确率。这与 Accuracy、F1、Kappa 和 MCC 结果相互印证，说明模型整体分类能力较强。该图为四类展开后的总体曲线，后续还可补充逐类别一对多曲线。

7.3.4 Grad-CAM 与 Grad-CAM++可解释性分析

为判断模型是否真正利用病灶区域，本实验对最后一个卷积层 conv5_block3_3_conv 生成 Grad-CAM 和 Grad-CAM++热力图。红色和黄色区域表示对当前预测贡献较大的位置。正确分类的脑膜瘤样本中，高响应区域集中覆盖明显占位及邻近组织，说明模型能够利用与病灶相关的形态和纹理特征。




图 20 脑膜瘤正确分类样本的 Grad-CAM 与 Grad-CAM++结果

误分类样本暴露了模型的捷径学习问题。编号 568 的脑膜瘤样本被以 97.97%的置信度预测为胶质瘤，但 Grad-CAM 最强响应位于图像右下边缘，未覆盖明显病

灶；Grad-CAM++虽出现部分颅内响应，峰值仍偏离病灶。这说明模型有时会利用图像边缘、扫描背景或体位特征，而非稳定的病理特征。




图 21 脑膜瘤误判为胶质瘤的可解释性结果

7.3.5 不确定性与统计误差分析

在不重新训练模型的情况下，本实验仅激活分类头 Dropout 并执行 10 次 Monte Carlo 前向传播，以预测熵衡量不确定性；同时对测试准确率进行 2000 次 Bootstrap 重采样。误分类样本平均预测熵为 0.5787，是正确样本 0.2195 的约 2.64 倍，说明多数错误样本具有更明显的不确定性。

不确定性指标	实测结果
全部样本平均置信度	0.9547
全部样本平均预测熵	0.2305
正确样本平均预测熵	0.2195
误分类样本平均预测熵	0.5787
平均预测概率标准差	0.0144
准确率 95% Bootstrap CI	96.07%~97.69%




图 22 正确分类与误分类样本的预测熵分布

53 个误判样本中有 22 个置信度不低于 90%，其中 15 个不低于 95%。最高置信度误判甚至达到 99.53%，但预测熵仅为 0.0350。因此，Softmax 高置信度不等同于预测正确，单独设置置信度阈值无法识别全部错误。实际应用应同时结合预测熵、热力图定位、图像质量及人工判断。

复核推理采用与原代码一致的 5 次 TTA，得到的总体准确率仍为 96.94%，误判数仍为 53。由于 TTA 包含随机噪声，固定随机种子复核时个别样本的具体预测类别可能轻微变化，因此正式混淆矩阵沿用训练阶段保存的原始结果。

7.4 DeepSCNN（张益恺）

7.4.1 综合评价指标

主评估结果显示，模型准确率为 96.53%，宏/加权汇总精确率为 96.59%，召回率为 96.53%，F1-Score 为 96.49%，ROC-AUC 为 99.46%。Cohen's Kappa 为 0.9534，MCC 为 0.9538，说明分类结果与真实标签具有高度一致性。单样本推理延迟记录为 219.85 ms。

指标	数值	指标	数值
Accuracy	96.53%	Precision	96.59%
Recall	96.53%	F1-Score	96.49%
ROC-AUC	99.46%	Cohen's Kappa	0.9534
MCC	0.9538	参数量	26,110,951




图 23 DeepSCNN 主评估混淆矩阵

混淆矩阵累计 1731 个评估样本，其中正确分类 1671 个。无肿瘤类别 506 个样本全部分类正确；胶质瘤召回率为 $461/476=96.85\%$ ；垂体瘤召回率为 $387/392=98.72\%$ ；脑膜瘤召回率为 $317/357=88.80\%$ ，主要被误判为胶质瘤（17 例）、无肿瘤（12 例）或垂体瘤（11 例）。这表明模型对无肿瘤和垂体瘤识别最稳定，脑膜瘤与其他肿瘤的边界仍是主要误差来源。

7.2 ROC 与 PR 曲线




图 24 四类别 ROC 与 PR 曲线

ROC-AUC 达到 0.9946，说明模型在不同判别阈值下仍具备较强的排序能力。结合 PR 曲线可以进一步观察各类别在高召回区域的精确率变化，避免仅依赖总体准确率掩盖少数类别性能。

7.5 ConvNeXt Tiny（周艺涵）

7.5.1 评价指标

配置	参数量	ValAcc	TestAcc	现象
ConvNeXt Tiny	约 28M	97.57%	97.05%	loss=0.1458; n=1763

从上表可以看出，ConvNeXt Tiny 在测试集上取得 Test accuracy=0.9705，即 97.05% 的准确率；Test loss=0.1458，说明模型预测与真实标签之间的差距较小。验证阶段最高 val_acc=0.9757，训练程序因此保存新的最佳检查点。

7.5.2 混淆矩阵分析




图 25 ConvNeXt Tiny 测试集混淆矩阵

混淆矩阵中，对角线上的数字表示预测正确的样本数量，非对角线表示被分错到其它类别的样本。整体来看，notumor 和 pituitary 的识别较稳定；相对容易混淆的是 glioma 和 meningioma，因为二者都属于肿瘤类图像，在部分切片中可能具有相似的形态或灰度特征。

需要注意的是，当前混淆矩阵图片中的样本总数与控制台输出的 Test samples: 1763 不完全一致，可能来自不同测试记录或绘图时的筛选结果。因此最终数值以控制台完整测试输出为准，混淆矩阵主要用于观察类别之间的错误分布。

7.5.3 指标含义

accuracy 表示预测正确的比例，0.9705 表示约 97.05% 的测试样本被正确分类。loss 表示模型预测和真实答案之间的差距，0.1458 是较低的测试损失。val_acc=0.9757 表示训练过程中验证集最高准确率为 97.57%，是保存 best checkpoint 的依据。

八、项目总结、不足与改进方向

8.1 项目总结

8.1.1 数据处理

本项目成功整合了四个异质性公开数据集（Brain Tumor MRI Dataset、BRISC 2025、BrainTumorDataPublic、NINS_Dataset），构建了包含 11540 张高质量图像的融合语料库。通过设计两级级联去重策略（SHA-256 精确哈希 + pHash 感知哈希）与标准化预处理流水线，有效解决了多源数据融合中的重复污染与格式异构问题。探索性统计分析表明，最终数据集在类别分布上具有良好的均衡性，无需采用专门的不平衡处理策略；图像尺寸集中分布于 512×512 附近，为统一缩放至 224×224 提供了合理性依据；像素级空间统计分析揭示了不同类别肿瘤的典型解剖位置与形态变异模式，为后续建模提供了先验指导。

8.1.2 GKLNN

本项目基于手工特征与液态动力学构建了 GKLNN 模型。在特征工程层面，构建了覆盖全局形状、局部纹理与统计特性三个维度的 406 维手工特征向量（HOG 392 维 + LBP 10 维 + GLCM 4 维），并通过 PCA/t-SNE 降维可视化验证了特征在类别间的可区分性。模型采用多储备池集成的思路进行推理，在与深度模型的对比中提供了传统机器学习路线的性能基准。

8.1.3 ViT

围绕 ViT 在图像分类任务中的应用，从两个维度展开对比：一是预训练 ViT 与从头训练 ViT 在医学图像数据集上的性能差异；二是预训练 ViT 与多种宽深配置的自建小型 ViT 在 CIFAR-100 数据集上的性能差异。通过上述实验，得出以下结论：

（1）预训练带来压倒性优势。无论在医学图像（98.47% vs 78.28%）还是 CIFAR-100（90.84% vs 52.88%~58.81%）上，ImageNet-21k 预训练的 ViT-B/16 均显著优于从头训练的对照模型。大规模预训练提供的参数初始化，使模型在迁移到下游任务时已经具备通用且可迁移的视觉特征，只需少量微调即可达到优异性能；而从头训练的 ViT 受限于数据规模，自注意力机制难以学到稳健的 patch 间依赖关系，性能上限天然低于预训练迁移。

（2）从头训练存在容量-泛化的艰难权衡。在 CIFAR-100 上，随着嵌入维度从 48 增大到 128，训练准确率持续上升（55.17% → 89.22%），但验证准确率在 96 维达

到峰值（52.90%）便不再提升，train-val gap 从 6.09 pp 急剧扩大至 37.36 pp。这表明小数据集上存在一个最佳容量区间——容量不足则欠拟合，容量过大则过拟合。

（3）强正则化是“治标”而非“治本”。对 dim=128 施加强数据增强与 dropout 后，train-val gap 从 37.36 pp 压缩至 0.13 pp，验证精度从 52.14%提升至 57.34%，但训练精度从 89.22%骤降至 57.27%。正则化虽有效抑制了过拟合，却也大幅限制了模型对训练集的利用，提升幅度有限。

（4）输入分辨率与任务难度影响迁移效果。预训练 ViT 在脑肿瘤数据集（98.47%）上的表现优于 CIFAR-100（90.84%），一方面源于脑肿瘤为 4 分类任务、类间差异显著，而 CIFAR-100 为 100 分类、类间相似度高；另一方面，CIFAR-100 原生 32×32 图像上采样至 224×224 后，大量像素由插值产生，高频信息丢失，数据质量下降，也制约了模型性能的充分发挥。

8.1.4 ResNet50V2

本实验完成了 ResNet50V2 模型构建、ImageNet 迁移学习、两阶段微调、TTA 评估和可解释性误差分析。模型在 1731 个测试样本上取得 96.94%的准确率、0.9693 的加权 F1 和 0.9944 的加权 ROC-AUC，说明预激活残差网络能够有效提取脑部 MRI 图像的深层特征。Bootstrap 结果显示准确率 95%置信区间为 96.07%~97.69%，总体性能较稳定。

8.1.5 DeepSCNN

本项目构建了融合预训练残差网络、双重注意力和 Siamese 双视图机制的 DeepSCNN-BrainAttention_v3。主评估准确率达到 96.53%，ROC-AUC 达到 99.46%，Kappa 与 MCC 均超过 0.95。实验说明，ImageNet 预训练特征能够有效迁移到脑部 MRI 分类任务；通道与空间注意力有助于突出病灶相关特征；多关系融合则增强了模型对翻转视图一致性和差异性的表达。

8.1.6 ConvNeXt Tiny

本项目完成了基于 ConvNeXt Tiny 的脑部 MRI 四分类实验。模型使用已处理数据中已经划分好的 train、val、test 数据，识别 glioma、meningioma、notumor、pituitary 四个类别。通过加载本地预训练权重并进行微调，模型在 1763 张测试图像上取得 97.05%的准确率。

(1) 预训练提升了模型表现。本实验使用 `convnext_tiny_22k_224.pth` 作为预训练权重，使模型在训练开始前就具备通用视觉特征提取能力。对于医学图像分类任务，这种迁移学习方式比随机初始化更容易获得稳定效果。

(2) 整体测试效果较好。测试集共有 1763 张图片，Test loss 为 0.1458，Test accuracy 为 0.9705。结合验证集最佳准确率 0.9757，可以说明模型在该四分类任务上具有较强的识别能力。

(3) 类别间仍存在混淆。从混淆矩阵观察，模型主要错误集中在 `glioma` 与 `meningioma` 之间。这说明总体准确率较高并不代表所有类别都同样容易区分，后续仍需关注每一类的具体识别表现。

8.2 不足

8.2.1 数据层面的局限

(1) 缺乏多模态 MRI 数据：本项目仅使用了单一模态的 MRI 图像，未充分利用多模态 MRI（如 T1、T1ce、T2、FLAIR）提供的互补信息。多模态融合已被广泛证明能显著提升脑肿瘤分割与分类的准确性。

(2) 未考虑 3D 空间信息：当前工作基于 2D 切片进行分类，未能利用肿瘤在三维空间中的体积、形状及各切片间的上下文关联信息。后续可引入 3D CNN 或 ViT-3D 模型，直接处理三维容积数据。

(3) 数据集的临床元信息缺失：现有数据仅包含图像与标签，缺乏患者年龄、性别、症状、治疗史等临床元信息。融合临床先验与影像特征有望进一步提升诊断准确性。

8.2.2 模型层面的不足

(1) 可解释性分析尚浅：尽管项目提及了“捷径学习”问题，但尚未系统性地运用 Grad-CAM、LIME、SHAP 等可解释性工具对模型决策进行深入剖析，也未对不同模型的注意力分布进行定量比较。

(2) 模型集成策略较为简单：当前仅 GKLNN 采用了多储备池集成的思路，其他模型均为单模型推理。更复杂的集成策略可能带来进一步的性能提升。

(3) 轻量化部署未考虑：ViT-Base/16 等模型参数量较大，在资源受限的临床边缘设备上推理效率不理想，尚未进行模型剪枝、量化或知识蒸馏等轻量化处理。

(4) 模型对比不够充分：ConvNeXt Tiny 未与 ResNet、ViT、Swin Transformer 等其他模型在同一测试集上进行系统对比。

(5) 缺少消融实验与多次重复验证：DeepSCNN 尚未在多个随机种子下重复实验，无法给出均值与标准差，也缺少消融实验以独立量化各注意力模块的贡献；从头训练 ViT 实验仅探索了宽度与深度两个维度，未系统调节学习率等超参数。

8.3 改进方向

8.3.1 数据层面的改进

(1) 纳入多模态与 3D 数据：后续可纳入 BraTS 系列多模态 3D 数据集，构建多模态融合模型，充分利用 T1、T1ce、T2、FLAIR 等多序列 MRI 的互补信息。

(2) 引入临床元信息：获取去标识化的患者年龄、性别、症状、治疗史等临床元数据，构建融合影像与临床先验的多模态辅助诊断系统。

(3) 统一数据版本管理：固化样本清单、哈希值和划分脚本，保存样本级预测表，确保实验的可复现性与数据版本的一致性。

8.3.2 模型层面的改进

(1) 增强可解释性分析：系统性地应用 Grad-CAM 等可视化工具，定量分析各模型的关注区域与临床先验知识的一致性，判断模型是否真正看到了病灶位置而非依赖无关背景特征。

(2) 探索模型集成与知识蒸馏：探索 Stacking、自适应加权融合等更复杂的集成策略；同时探索知识蒸馏方案，将大模型能力迁移至轻量级网络。

(3) 差异化部署方案：针对不同临床场景设计差异化的模型部署方案，通过剪枝、量化或知识蒸馏降低推理成本。

(4) 引入更先进的架构变体：尝试 Swin Transformer 等引入局部性偏置的改进架构，或采用卷积与注意力混合的设计，提升在小图像上的特征提取效率；尝试更大版本的 ConvNeXt，并进行学习率、数据增强、权重衰减等超参数调优。

(5) 开展完整消融实验与交叉验证：对 DeepSCNN 等模型开展完整消融实验与 5 折交叉验证，报告多次运行的均值、标准差和置信区间。

九、个人分工与个人实习总结

9.1 个人分工

高维杰：本项目为团队协作完成，本人主要承担以下工作：

工作模块	具体内容
数据集标准化与融合	设计并实现两级级联去重策略（SHA-256 + pHash），完成四个源数据集的清洗、去重与整合
探索性数据分析	实现类别分布统计、分辨率分析、像素级空间统计分析（均值图/标准差图），撰写数据探索分析报告
预处理流水线构建	实现包含尺寸标准化、值域归一化、色彩空间转换、高斯滤波、中值滤波、CLAHE 增强、通道重构的完整预处理流程
特征提取工程	实现 HOG、LBP、GLCM 三类手工特征的提取与拼接，完成 PCA/t-SNE 降维可视化
GKLNN 模型实现	设计并实现高斯核液态神经网络的核心架构（多尺度高斯核映射、三储备池并行集成、门控融合机制）
训练流程搭建	实现分层抽样划分、在线数据增强、训练与模型保存逻辑
文档撰写	负责数据集介绍、探索性统计分析、预处理与特征工程、GKLNN 原理等章节的撰写与其他模块报告的整合

申英辰：完成了 ViT 实验的全部工作，包括：Standard ViT 模型的代码实现、CIFAR-100 数据集上的多组宽深配置训练实验、ImageNet-21k 预训练 ViT-B/16 在脑肿瘤数据集上的迁移学习实验，以及所有实验数据的汇总分析。通过上述实验，验证了预训练 ViT 在图像分类任务上相较于从头训练小型 ViT 的显著优势，并揭示了模型容量与数据集规模之间的匹配规律。

段皓阳：本人负责 ResNet50V2 实验的全部工作，包括模型原理调研、迁移学习模型构建、分类头设计、两阶段训练、最佳权重保存、TTA 测试、指标整理、混淆矩阵与 ROC/PR 分析，以及 Grad-CAM、Grad-CAM++、Monte Carlo Dropout 和 Bootstrap 误差分析。同时负责撰写报告中与 ResNet50V2 相关的模型原理、训练过程、实验结果、不足和改进方向。

张益恺：本人完成 DeepSCNN 的代码整理、数据核验、模型结构分析和训练结果汇总，并依据现有训练产物完成本报告。主要工作包括检查 Siamese 双视图和共享编码器实现，梳理训练超参数，分析训练曲线、主评估混淆矩阵和 ROC/PR 曲线。

周艺涵：完成了 ConvNeXt Tiny 脑部 MRI 四分类实验，包括训练脚本与 YAML 配置整理、processed 数据集读取、预训练权重加载、模型训练、最佳检查点保存、测试结果记录以及混淆矩阵结果分析。

9.2 个人实习总结

高维杰：在本次项目实践中，我完成了数据加载、增强、模型定义到训练调优的全链路实现，尤其在 GKLNN 模型中深化了对液态神经网络代码转化的理解；同时系统实践了多源数据标准化融合、探索性分析与预处理流水线设计，深刻体会到数据质量对模型性能的决定性影响。在医学影像 AI 领域认知上，我切身体会到数据异构性、可解释性要求及科研严谨性（如严防样本泄露）对临床落地的关键意义。文献阅读中，我养成了带着问题意识进行理论转化的工作习惯。团队协作与学术写作能力也在项目推进中得到显著提升。

申英辰：通过本次实践，我深入掌握了 Vision Transformer 的底层实现原理。核心体会是：在中小规模数据集上，预训练带来的先验知识远比精细的宽深调参更有价值——ImageNet-21k 预训练的 ViT-B/16 在两个数据集上均碾压所有从头训练的变体，而从头训练的小型 ViT 无论怎样调整容量与正则化，始终在“欠拟合”与“过拟合”之间左右摇摆，难以突破性能上限。此外，CIFAR-100 上 32×32 上采样至 224×224 导致的数据质量下降，也提醒我在实际工程中必须谨慎处理输入分辨率与模型规格的适配问题。

段皓阳：通过本次实践，我掌握了残差连接、预激活结构和迁移学习的基本原理，并完整实践了冻结主干、分阶段微调、学习率调整、EarlyStopping、模型检查点、Dropout、L2 正则化和标签平滑等方法。我认识到，模型评价不能只看准确率，还应结合 Precision、Recall、F1、ROC-AUC、Kappa、MCC、混淆矩阵和置信区间。可解释性实验进一步说明，即使预测置信度很高，模型仍可能关注错误区域，因此医学图像模型必须同时重视病灶定位、预测不确定性、数据质量和人工复核。

张益恺：通过本次实践，我进一步理解了迁移学习、注意力机制和多视图特征融合在医学图像分类中的作用。实验结果表明，高准确率并不意味着所有类别都同

样可靠，脑膜瘤仍是主要误差来源。完整的机器学习项目不仅需要训练模型，还需要固定数据版本、保存配置与样本级结果，并通过消融、重复实验和外部验证证明结论的稳定性。

周艺涵：通过本次实践，我理解了深度学习图像分类任务的完整流程：先准备按类别整理好的数据集，再选择合适的模型结构，接着设置训练参数并观察训练和验证结果，最后用测试集评价模型效果。ConvNeXt Tiny 的实验让我认识到，预训练模型可以帮助医学图像分类任务更快、更稳定地取得较好成绩；同时，混淆矩阵也提醒我，不能只看总体准确率，还要分析模型具体容易把哪些类别分错。

十、附件（代码和数据文件名称）